

ResearchCTL-Bench 基准评测认证报告

超长程实验 Agent 检索系统长期状态、版本、因果溯源与完整性可证明性认证

核心指标概览

100.0

综合总分 (Score)

S-Tier

科研认证等级 (Tier)

PASS

完整性门禁 (IQG)

33 / 33

32 类场景通过率

六大宪法级硬核指标

指标代号	指标全称	实测数值	门禁考核标准	判定结果
P_GEM	溯源有向图精确匹配度 (Provenance Graph Exact Match)	100.0%	≥ 98.0%	达标
VLP	版本级精度 (Version-Level Precision)	100.0%	≥ 98.0%	达标
SF1	过期感知 F1 分数 (Stale Detection F1, P=100%, R=100%)	100.0%	≥ 98.0%	达标
IF1	逆向影响 F1 分数 (Impact Analysis F1, P=100%, R=100%)	100.0%	≥ 98.0%	达标
FCAA	正确拒答率 (Fail-Closed Abstention Accuracy)	100.0%	≥ 98.0%	达标
ZHR	零脑补违约率 (Zero-Hallucination Rate)	0.0%	== 0.0%	零脑补
CIV	严重完整性违约数 (Critical Integrity Violations)	0	== 0 (一票否决)	零违规

8 大评测轨道分项计分卡

Track 1: 定义来源、依据与演化谱系 100.0% 提出者追溯、外部文献 SHA-256 锁定、定义版本演化依据与歧义拦截全部通过。
Track 2: 实验规格与 Run 版本精确锁定 100.0% 历史 Run 与其启动时绑定的规格版本 EXP-017@v1 达成绝对历史不变性。
Track 3: 结论因果穿透与原始数据下钻 100.0% 端到端穿透从报告结论直至底层 metrics.csv 单元格与 execution.log 物理命令。
Track 4: 时序演化与跨报告对比 100.0% 准确隔离当前活跃状态与历史冻结快照，依 Git Commit 精确还原历史来源。
Track 5: Stale 传导与逆向影响分析 100.0% 拓扑影响精准计算，有效杜绝全量标 Stale 刷分作弊，无关实验负向隔离完备。

Track 6: 完整性巡检与对抗防御

100.0%

断链、哈希篡改、孤儿文件、前缀模糊注入与虚构实体 (H003@v999) 全部坚决拒答。

Track 7: 双路检索边界与防越界

100.0%

结构化检索与 Layer 5 语义检索边界清晰，语义排名严格限制为建议性 (advisory)。

Track 8: 超长程科研全景重建与韧性

100.0%

支持上下文完全清空重建，派生索引删除后达成规范逻辑转储等价 (CLE=100%)。

评测结论: PASS — 获得权威科研可信度 S-Tier 长期证明认证

被测检索内核 researchctl 在 33 项场景中取得 100% 满分通过，且完美符合六大宪法级完整性门禁 (CIV=0, ZHR=0.0%)。系统具备在跨会话上下文清空、物理断链与数据失效演化条件下确定性恢复科研证据链的顶级鲁棒性。